



Generación de Variables Aleatorias Continuas

Miguel Ángel Rincón Morales¹

1. Cod: 160005038, Ing. Sistemas.

Facultad de Ciencias Básicas e Ingenierías. Programa de Ingeniería de Sistemas.

Fecha: 25 de Septiembre de 2026

Resumen

Este informe documenta la implementación y validación de generadores de variables aleatorias continuas y de procesos de Poisson. Todos los números aleatorios provienen del generador congruencial mixto de módulo $m = 2^{48}$ seleccionado en el Laboratorio 2, cuya uniformidad y aleatoriedad se verificaron de nuevo sobre 1000 valores ($\chi^2 = 13,74 < 16,92$; $|Z| = 1,45 < 1,96$). Con el método de la transformada inversa se generaron 1000 valores de las cuatro distribuciones de la guía (una densidad exponencial truncada, una densidad triangular por tramos, la distribución $F(x) = (x^2 + x)/2$ y una Weibull), y en los cuatro casos la prueba de Kolmogórov-Smirnov no rechazó la distribución objetivo (p -valores entre 0,16 y 0,66). Se implementaron además generadores exponencial, Gamma (por suma de exponenciales y por rechazo) y normal estándar (por el método polar y por rechazo), midiendo tasas de aceptación de 0,795, 0,772 y 0,763 frente a los valores teóricos $1/c = 0,795$, $\pi/4 = 0,785$ y 0,760. Con estos bloques se generó un proceso de Poisson de tasa $\lambda = 2$ en $[0, 10]$ (2000 réplicas: $\bar{N}(T) = 19,94$ frente a $\lambda T = 20$), una variable aleatoria de Coxian ($\bar{X} = 2,837$ frente a $E[X] = 2,840$) y un proceso de Poisson no homogéneo por adelgazamiento, comparando la versión básica con la versión por subintervalos, que produce la misma distribución ($\bar{N}(10) = 69,9$ frente a $m(10) = 70$) con 2,5 veces menos candidatos.

Palabras clave — variables aleatorias continuas, transformada inversa, método del rechazo, método polar, distribución exponencial, distribución Gamma, proceso de Poisson, proceso de Poisson no homogéneo, adelgazamiento.

1. Objetivos

- Generar secuencias de valores de una variable aleatoria de una distribución de probabilidad continua.
- Generar valores aleatorios de una distribución de probabilidad continua usando el método de la transformada inversa.
- Generar valores aleatorios de una distribución de probabilidad continua usando el método del rechazo.
- Generar valores aleatorios de una distribución de probabilidad continua usando el método polar para generar variables aleatorias normales.
- Generar valores aleatorios de una distribución exponencial.
- Generar valores aleatorios de una distribución de probabilidad Gamma.



- Generar valores aleatorios de una distribución de probabilidad Normal estándar.
- Generar variables aleatorias de procesos de Poisson y procesos de Poisson no homogéneos.

2. Fundamento teórico

Los métodos que siguen corresponden a las diapositivas de clase *Generación de Variables Aleatorias Continuas* [1] y al Capítulo 5 de [2], secciones 5.1 a 5.5.

2.1. Método de la transformada inversa

Si $U \sim U(0,1)$ y F es una función de distribución continua y estrictamente creciente, la variable $X = F^{-1}(U)$ tiene distribución F [2], ya que

$$P\{X \leq x\} = P\{F^{-1}(U) \leq x\} = P\{U \leq F(x)\} = F(x) \quad (1)$$

El método consume exactamente una uniforme por valor generado y es el preferido siempre que F^{-1} pueda escribirse en forma cerrada o evaluarse a bajo costo. Las cuatro distribuciones de la sección 5.1 de la guía cumplen esa condición, con las inversas deducidas en la sección 3.2.

2.2. Método del rechazo

Para generar X con densidad f se elige una densidad g fácil de simular y una constante $c \geq \sup_x f(x)/g(x)$; se genera $Y \sim g$ y $U \sim U(0,1)$ independientes, y se acepta $X = Y$ si

$$U \leq \frac{f(Y)}{cg(Y)} \quad (2)$$

repetiendo en caso contrario. El valor aceptado tiene densidad f , cada intento se acepta con probabilidad $1/c$ y el número de intentos es geométrico con media c [2]; por eso conviene elegir g de modo que c sea lo más cercano posible a 1. Dos aplicaciones clásicas son la Gamma($\frac{3}{2}, 1$) con envolvente exponencial de tasa $\frac{2}{3}$, para la cual $c = 3^{3/2}/\sqrt{2\pi e} \approx 1,257$, y el valor absoluto de una normal estándar con envolvente exponencial de tasa 1, para la cual $c = \sqrt{2e/\pi} \approx 1,315$.

2.3. Método polar para generar variables aleatorias normales

Descrito en la sección 5.3 de [2], evita las funciones trigonométricas del método de Box–Muller. Se generan $V_1, V_2 \sim U(-1,1)$ hasta que $S = V_1^2 + V_2^2 \leq 1$ (el punto cae dentro del círculo unitario); entonces

$$X = \sqrt{\frac{-2 \ln S}{S}} V_1, \quad Y = \sqrt{\frac{-2 \ln S}{S}} V_2 \quad (3)$$

son normales estándar independientes. La probabilidad de aceptación es el cociente entre el área del círculo y la del cuadrado, $\pi/4 \approx 0,785$, y cada par aceptado produce dos normales.

2.4. Generación de un proceso de Poisson

Un proceso de Poisson con tasa λ es un proceso de conteo $\{N(t), t \geq 0\}$ con $N(0) = 0$, incrementos independientes y estacionarios, tal que $N(t+s) - N(s) \sim \text{Poisson}(\lambda t)$. Equivalentemente, los tiempos entre eventos son exponenciales i.i.d. de tasa λ , con $f(x) = \lambda e^{-\lambda x}$ y $F(x) = 1 - e^{-\lambda x}$, de modo que las primeras T unidades de tiempo se generan con el algoritmo de la sección 5.4 de [2]:



PASO 1: $t = 0, I = 0$. PASO 2: Generar U . PASO 3: $t = t - \frac{1}{\lambda} \ln U$; si $t > T$, terminar.
PASO 4: $I = I + 1, S(I) = t$. PASO 5: Ir al paso 2.

2.5. Generación de un proceso de Poisson no homogéneo

En un proceso de Poisson no homogéneo la intensidad $\lambda(t)$ varía con el tiempo: los incrementos siguen siendo independientes pero no estacionarios, $N(t+s) - N(s) \sim \text{Poisson}(m(t+s) - m(s))$ con $m(t) = \int_0^t \lambda(y) dy$, y los tiempos entre eventos dejan de ser exponenciales i.i.d. Si $\lambda(t) \leq \lambda_{\text{máx}}$ para todo $t \leq T$, se genera un proceso homogéneo de tasa $\lambda_{\text{máx}}$ y cada uno de sus eventos, ocurrido en t , se acepta con probabilidad $\lambda(t)/\lambda_{\text{máx}}$ (adelgazamiento o *thinning*). Cuando $\lambda(t)$ varía mucho, el método desperdicia candidatos en las zonas de intensidad baja; la variante de la sección 5.5 de [2] parte $[0, T]$ en subintervalos $[t_{j-1}, t_j]$ con cotas locales $\lambda_j \geq \lambda(t)$ y aplica el adelgazamiento en cada uno. Por la falta de memoria de la exponencial, el proceso homogéneo de cada subintervalo puede generarse de manera independiente a partir de su extremo izquierdo. El número esperado de candidatos pasa de $\lambda_{\text{máx}}T$ a $\sum_j \lambda_j(t_j - t_{j-1})$.

3. Procedimiento o metodología

Todo el desarrollo se implementó en un único Notebook de Jupyter en Python ejecutado en Google Colab, Lab3_160005038.ipynb, adjunto a este informe. No se utilizó ninguna función de aleatoriedad de librería: todos los números aleatorios provienen del generador congruencial mixto implementado a mano. De `scipy` sólo se emplearon `stats` para las pruebas estadísticas y las densidades teóricas de referencia, `integrate` para las medias teóricas y `special` para la función Gamma.

3.1. Generador de números pseudoaleatorios

La guía exige usar buenos generadores congruenciales mixtos que cumplan los criterios de uniformidad y aleatoriedad. Se reutilizó el GLC-d del Laboratorio 2, $X_{i+1} = (25214903917 X_i + 11) \bmod 2^{48}$, que cumple las tres condiciones del teorema de Hull–Dobell y por lo tanto tiene periodo $2^{48} \approx 2,81 \times 10^{14}$. Antes de usarlo se validaron sus primeros 1000 valores con el contraste χ^2 ($k = 10$ clases) y el test de rachas, ambos con $\alpha = 0,05$, con las mismas funciones del Laboratorio 2. Cada ejercicio del laboratorio usa una semilla distinta para trabajar con flujos independientes, y el generador lleva un contador de uniformes consumidas que permite medir la eficiencia de cada método.

```
1 A, C, M = 25214903917, 11, 2**48
2
3 class GLC:
4     def __init__(self, X0, a=A, c=C, m=M):
5         self.X, self.a, self.c, self.m = X0, a, c, m
6         self.consumidos = 0
7     def uniforme(self):
8         self.X = (self.a * self.X + self.c) % self.m
9         self.consumidos += 1
10        return self.X / self.m
```

Bloque de código 1: Generador congruencial mixto con contador de uniformes consumidas.



3.2. Generación de variables aleatorias continuas (5.1)

Para cada apartado se dedujo la inversa de la función de distribución, se generaron $n = 1000$ valores y se comparó el histograma (normalizado como densidad) con la densidad teórica. Como validación numérica se calcularon la media muestral frente a la teórica (obtenida por cuadratura de $\int xf(x) dx$) y la prueba de Kolmogórov–Smirnov contra la F objetivo.

- (a) $f(x) = \frac{e^x}{e-1}$ en $[0, 1]$. Integrando, $F(x) = \frac{e^x-1}{e-1}$ y despejando $F(x) = U$:

$$X = \ln(1 + (e - 1)U) \quad (4)$$

- (b) $f(x) = \frac{x-2}{2}$ en $[2, 3]$ y $f(x) = \frac{2-x/3}{2}$ en $[3, 6]$. Integrando por tramos, $F(x) = \frac{(x-2)^2}{4}$ en $[2, 3]$, con $F(3) = \frac{1}{4}$, y $F(x) = x - \frac{x^2}{12} - 2$ en $[3, 6]$. Invertiendo cada tramo (en el segundo se resuelve $x^2 - 12x + 12(2 + U) = 0$):

$$X = \begin{cases} 2 + 2\sqrt{U} & U < \frac{1}{4} \\ 6 - 2\sqrt{3(1 - U)} & U \geq \frac{1}{4} \end{cases} \quad (5)$$

Este apartado se resolvió además por el método del rechazo con $g \sim U(2, 6)$ y $c = \sup f/g = \frac{1}{2} \cdot 4 = 2$ para comparar el costo de ambos métodos.

- (c) $F(x) = \frac{x^2+x}{2}$ en $[0, 1]$, con densidad $f(x) = x + \frac{1}{2}$. De $x^2 + x - 2U = 0$:

$$X = \frac{-1 + \sqrt{1 + 8U}}{2} \quad (6)$$

- (d) Weibull, $F(x) = 1 - \exp(-\alpha x^\beta)$. De $1 - U = \exp(-\alpha X^\beta)$:

$$X = \left(\frac{-\ln(1 - U)}{\alpha} \right)^{1/\beta} \quad (7)$$

con densidad $f(x) = \alpha\beta x^{\beta-1}e^{-\alpha x^\beta}$ y media $\alpha^{-1/\beta} \Gamma(1 + 1/\beta)$. Se usaron $\alpha = 2$ y $\beta = 1,5$.

```
1 def gen_a(g):
2     return math.log(1 + (math.e - 1) * g.uniforme())
3
4 def gen_b(g):
5     u = g.uniforme()
6     if u < 0.25:
7         return 2 + 2 * math.sqrt(u)
8     return 6 - 2 * math.sqrt(3 * (1 - u))
9
10 def gen_c(g):
11     return (-1 + math.sqrt(1 + 8 * g.uniforme())) / 2
12
13 def gen_d(g, alpha, beta):
14     return (-math.log(1 - g.uniforme()) / alpha) ** (1 / beta)
15
16 def gen_b_rechazo(g): # envoltente U(2,6), c = 2
17     while True:
18         y = 2 + 4 * g.uniforme()
19         if g.uniforme() <= f_b(y) / 0.5:
20             return y
```

Bloque de código 2: Generadores por transformada inversa de los apartados (a) a (d).



3.3. Generadores exponencial, Gamma y normal

Para cubrir los objetivos restantes de la guía y disponer de los bloques que necesitan las secciones 5.2 y 5.3, se implementaron: la exponencial por transformada inversa, $X = -\frac{1}{\lambda} \ln(1 - U)$ (se usa $1 - U$, también uniforme, para evitar $\ln 0$); la $\text{Gamma}(n, \lambda)$ con n entero como suma de exponenciales; la $\text{Gamma}(\frac{3}{2}, 1)$ por rechazo con envolvente exponencial de tasa $\frac{2}{3}$ (ejemplo 5d de [2]), aceptando Y si $U \leq \sqrt{2Y/3} e^{1/2 - Y/3}$; la normal estándar por el método polar; y la normal estándar por rechazo (ejemplo 5e de [2]), generando $Y_1, Y_2 \sim \text{Exp}(1)$, aceptando $|Z| = Y_1$ si $Y_2 \geq (Y_1 - 1)^2/2$ y asignando el signo con una tercera uniforme. Con cada uno se generaron 1000 valores.

```
1 def exponencial(g, lam=1.0):
2     return -math.log(1 - g.uniforme()) / lam
3
4 def gamma_32_rechazo(g):
5     while True:
6         y = exponencial(g, 2 / 3)
7         if g.uniforme() <= math.sqrt(2 * y / 3) * math.exp(0.5 - y / 3):
8             return y
9
10 def normal_polar(g):
11     # devuelve un par de normales independientes
12     while True:
13         v1, v2 = 2 * g.uniforme() - 1, 2 * g.uniforme() - 1
14         s = v1 * v1 + v2 * v2
15         if 0 < s <= 1:
16             k = math.sqrt(-2 * math.log(s) / s)
17             return v1 * k, v2 * k
18
19 def normal_rechazo(g):
20     while True:
21         y1, y2 = exponencial(g), exponencial(g)
22         if y2 >= (y1 - 1) ** 2 / 2:
23             return y1 if g.uniforme() < 0.5 else -y1
```

Bloque de código 3: Generadores exponencial, $\text{Gamma}(3/2)$ por rechazo y normal por el metodo polar y por rechazo.

3.4. Procesos de Poisson (5.2)

(a) Se implementó el algoritmo de la sección 5.4 de [2] y se ilustró con $\lambda = 2$ y $T = 10$. Para validarlo se generaron 2000 réplicas y se comprobó que $N(T)$ se distribuye $\text{Poisson}(\lambda T = 20)$ (media, varianza y contraste χ^2) y que los tiempos entre llegadas —las $N(T) + 1$ exponenciales generadas en cada réplica, incluida la que cruza T — son exponenciales de media $1/\lambda = 0,5$.

(b) Para la variable de Coxian, el trabajador completa la etapa i en un tiempo $\text{Exp}(\lambda_i)$ y pasa a la etapa $i + 1$ con probabilidad α_i ; tras la etapa k el trabajo termina, lo que equivale a $\alpha_k = 0$. El algoritmo propuesto es:

PASO 1: $X = 0, i = 1$. PASO 2: Generar U y hacer $X = X - \frac{1}{\lambda_i} \ln U$. PASO 3: Si $i = k$, terminar. Generar U' : si $U' < \alpha_i$, hacer $i = i + 1$ e ir al paso 2; en caso contrario, terminar.

Si $\pi_i = \prod_{j < i} \alpha_j$ es la probabilidad de llegar a la etapa i , entonces $E[X] = \sum_{i=1}^k \pi_i / \lambda_i$ y X es una mezcla de hipoexponenciales: con probabilidad $\pi_j(1 - \alpha_j)$ el tiempo es la suma de las j primeras exponenciales, cuya densidad, para tasas distintas, es $\sum_{i \leq j} \lambda_i e^{-\lambda_i x} \prod_{l \neq i} \frac{\lambda_l}{\lambda_l - \lambda_i}$. Esta densidad se calculó para contrastar el histograma. Se usaron $k = 3, \lambda = (1, 0,5, 2)$ y $\alpha = (0,8, 0,6, 0)$, y se generaron 10.000 valores.



```
1 def proceso_poisson(g, lam, T):
2     t, S = 0.0, []
3     while True:
4         t += exponencial(g, lam)
5         if t > T:
6             break
7         S.append(t)
8     return np.array(S)
9
10 def coxian(g, lam, alpha):
11     X, etapas = 0.0, 0
12     for i in range(len(lam)):
13         X += exponencial(g, lam[i]); etapas += 1
14         if g.uniforme() >= alpha[i]: # con prob. 1 - alpha_i deja el trabajo
15             break
16     return X, etapas
```

Bloque de código 4: Proceso de Poisson y variable aleatoria de Coxian.

3.5. Proceso de Poisson no homogéneo (5.3)

La intensidad es $\lambda(t) = t/5$ en $0 < t < 5$ y $\lambda(t) = 1 + 5(t - 5)$ en $5 < t < 10$, continua en $t = 5$, con $\lambda_{\text{máx}} = \lambda(10) = 26$. Su función de valor medio es $m(t) = t^2/10$ para $t \leq 5$ y $m(t) = 2,5 + (t - 5) + 2,5(t - 5)^2$ para $t \geq 5$, de modo que $E[N(5)] = 2,5$ y $E[N(10)] = 70$. Se implementaron dos versiones del adelgazamiento: la **básica**, con $\lambda_{\text{máx}} = 26$ en todo $[0, 10]$, y la **por subintervalos**, con cotas $\lambda_1 = 1$ en $[0, 5]$, $\lambda_2 = 13,5$ en $[5; 7,5]$ y $\lambda_3 = 26$ en $[7,5; 10]$. Ambas se compararon en una realización con la misma semilla y en 1000 réplicas, midiendo $N(10)$, $N(5)$, el número de candidatos y la tasa de aceptación. La intensidad empírica se estimó agrupando los tiempos de evento de las 1000 réplicas en clases de amplitud 0,25 y dividiendo por (réplicas $\times$ amplitud).

```
1 def lam_t(t):
2     return t / 5 if t < 5 else 1 + 5 * (t - 5)
3
4 def nhpp_basico(g, lam_fn, lam_max, T):
5     t, S, cand = 0.0, [], 0
6     while True:
7         t += exponencial(g, lam_max)
8         if t > T: break
9         cand += 1
10        if g.uniforme() <= lam_fn(t) / lam_max:
11            S.append(t)
12    return np.array(S), cand
13
14 def nhpp_intervalos(g, lam_fn, bordes, cotas):
15     S, cand = [], 0
16     for a, b, lm in zip(bordes[:-1], bordes[1:], cotas):
17         t = a # reinicio valido por falta de memoria
18         while True:
19             t += exponencial(g, lm)
20             if t > b: break
21             cand += 1
22             if g.uniforme() <= lam_fn(t) / lm:
23                 S.append(t)
24    return np.array(S), cand
```

Bloque de código 5: Adelgazamiento basico y por subintervalos para el proceso de Poisson no homogéneo.



4. Resultados y análisis

4.1. Validación del generador de números pseudoaleatorios

Los primeros 1000 valores del GLC con semilla 2391 dieron $\chi^2 = 13,740$ frente al valor crítico $\chi^2_{9;0,05} = 16,919$ (p -valor 0,132) y $R = 647$ rachas con $Z = -1,451$ frente a $Z_{0,025} = 1,960$; la media muestral fue 0,5001 y la varianza 0,0790 (teórica $1/12 = 0,0833$). El generador cumple, por tanto, los criterios de uniformidad y aleatoriedad exigidos por la guía, además de tener un periodo varios órdenes de magnitud mayor que las aproximadamente 10^6 uniformes que consume todo el laboratorio.

4.2. Generación de variables aleatorias continuas (5.1)

La Tabla 1 muestra los primeros diez valores de cada apartado, la Figura 1 compara los histogramas de los 1000 valores con las densidades teóricas y la Tabla 2 resume la validación numérica.

i	(a) $e^x/(e-1)$	(b) triangular	(c) $F = (x^2 + x)/2$	(d) Weibull(2; 1,5)
1	0.3134	4.5786	0.7918	0.4106
2	0.8242	3.6160	0.6488	0.3430
3	0.7588	3.5598	0.5436	0.7573
4	0.8351	2.2216	0.4313	0.5706
5	0.8528	4.9682	0.2802	0.8953
6	0.5154	5.1480	0.6312	0.0725
7	0.7586	2.3978	0.3266	0.4196
8	0.9337	2.9824	0.6116	0.8829
9	0.4743	5.1034	0.8812	0.8221
10	0.8093	4.0083	0.1404	0.8227

Tabla 1: Primeros diez valores generados por transformada inversa en cada apartado de 5.1 (semillas 2391, 29022024, 7919 y 4567 respectivamente).




Figura 1: Histograma (densidad empírica) de los 1000 valores generados en cada apartado de 5.1 frente a la densidad teórica (línea roja).

Distribución	Media muestral	Media teórica	Desv. muestral	KS D	KS p -valor
(a) $e^x/(e-1)$	0.5842	0.5820	0.2734	0.0308	0.2924
(b) triangular 2-3-6	3.6704	3.6667	0.8320	0.0229	0.6597
(c) $F(x) = (x^2 + x)/2$	0.5774	0.5833	0.2737	0.0255	0.5231
(d) Weibull($\alpha = 2, \beta = 1,5$)	0.5901	0.5687	0.3898	0.0355	0.1579

Tabla 2: Validación de las cuatro muestras de $n = 1000$ valores: media muestral frente a teórica y prueba de Kolmogórov-Smirnov contra la distribución objetivo ($\alpha = 0,05$).

En los cuatro apartados el histograma sigue la forma de la densidad teórica: creciente y convexa en (a), triangular asimétrica con moda en $x = 3$ en (b), lineal creciente en (c) y con moda cercana a $x \approx 0,3$ y cola derecha en (d). Las medias muestrales difieren de las teóricas en menos de 0,022, del orden del error estándar esperable ($s/\sqrt{n} \approx 0,009$ en (a), (c) y (d) y 0,026 en (b)), y la prueba KS no rechaza ninguna de las distribuciones objetivo: el menor p -valor es 0,158 en la Weibull, muy por encima de 0,05. El resultado confirma tanto las inversas deducidas en la sección 3.2 como la calidad del flujo de uniformes.

La comparación del apartado (b) por los dos métodos ilustra el costo del rechazo. Con la transformada inversa cada valor consume exactamente una uniforme; con la envolvente $U(2,6)$ y $c = 2$ los 1000 valores consumieron 3,830 uniformes por valor (teórico $2c = 4$), con una tasa de aceptación observada de 0,522 frente a la teórica $1/c = 0,5$. Ambas muestras son igualmente válidas (media 3,6397 y KS $p = 0,418$ para el rechazo, frente a 3,6704 y $p = 0,660$ para la inversa, con media teórica $11/3 = 3,6667$), de modo que cuando F^{-1} tiene forma cerrada la transformada inversa es el método apropiado y el rechazo sólo se justifica cuando no la tiene.



4.3. Generadores exponencial, Gamma y normal

La Figura 2 y la Tabla 3 recogen los resultados de los generadores auxiliares.




Figura 2: Histogramas de 1000 valores generados de la exponencial(1), de la $\text{Gamma}(\frac{3}{2}, 1)$ por rechazo y de la normal estándar por el método polar y por rechazo, frente a la densidad teórica.

Distribución y método	Media	Media teó.	Var.	Var. teó.	KS p	Unif./valor	Aceptación (teó.)
Exponencial(1), inversa	1.0196	1.0	0.9596	1.00	0.2546	1.000	—
Gamma(3, 2), suma de exponenciales	1.4872	1.5	0.7327	0.75	0.6908	3.000	—
Gamma($\frac{3}{2}$, 1), rechazo	1.4796	1.5	1.4950	1.50	0.6766	2.516	0.795 (0.795)
Normal(0, 1), método polar	-0.0463	0.0	0.9495	1.00	0.0854	1.296	0.772 (0.785)
Normal(0, 1), rechazo	0.0069	0.0	0.9982	1.00	0.9973	3.622	0.763 (0.760)

Tabla 3: Validación y eficiencia de los generadores auxiliares sobre $n = 1000$ valores. La última columna compara la tasa de aceptación observada con la teórica ($1/c$ en el rechazo, $\pi/4$ en el método polar).

Los cinco generadores reproducen la media y la varianza de su distribución y superan la prueba KS. Las tasas de aceptación medidas con el contador de uniformes coinciden con las teóricas: 0,795 para la $\text{Gamma}(\frac{3}{2})$ (teórica $1/c = \sqrt{2\pi e}/3^{3/2} = 0,795$), 0,772 para el método polar ($\pi/4 = 0,785$) y 0,763 para la normal por rechazo ($\sqrt{\pi/2e} = 0,760$). En términos de costo, el método polar es el más eficiente para la normal —1,30 uniformes por valor, porque cada par aceptado produce dos normales— frente a 3,62 del rechazo, que además necesita dos logaritmos y una uniforme extra para el signo. El método polar fue el que presentó el p -valor más bajo del laboratorio (0,085, con media muestral -0,046); sigue sin rechazarse al 5 %, y es el comportamiento esperable de una de varias pruebas sobre muestras de tamaño 1000.



4.4. Procesos de Poisson (5.2)

(a) Primeras T unidades de tiempo de un proceso de Poisson

La realización con $\lambda = 2$, $T = 10$ y semilla 2024 produjo $N(T) = 22$ eventos; la Tabla 4 lista los doce primeros. La Figura 3 muestra cuatro realizaciones de $N(t)$ junto a su valor esperado λt y, a la derecha, la distribución de $N(T)$ en 2000 réplicas frente a la masa de una Poisson(20).

Evento I	Tiempo $S(I)$	Tiempo entre eventos
1	0.1000	0.1000
2	0.4268	0.3267
3	1.5029	1.0761
4	2.2190	0.7161
5	2.2621	0.0431
6	2.4189	0.1569
7	3.1273	0.7084
8	3.8436	0.7163
9	3.9681	0.1245
10	4.6484	0.6803
11	4.8169	0.1685
12	5.0040	0.1871

Tabla 4: Primeros doce eventos de una realización del proceso de Poisson con $\lambda = 2$ en $[0, 10]$ ($N(T) = 22$ eventos en total).




Figura 3: Izquierda: cuatro realizaciones de $N(t)$ para $\lambda = 2$, $T = 10$, junto a $E[N(t)] = \lambda t$. Derecha: distribución empírica de $N(T)$ en 2000 réplicas frente a la masa de Poisson(20).

En las 2000 réplicas la media de $N(T)$ fue 19,938 y su varianza 21,732, frente al valor teórico $\lambda T = 20$ para ambas; el contraste χ^2 de $N(T)$ contra Poisson(20) dio $\chi^2 = 11,597$ con 20 grados de libertad ($p = 0,929$). Los 41.876 tiempos entre eventos generados tuvieron media 0,5008 (teórica 0,5) y la prueba KS contra Exp(2) dio $p = 0,895$. El proceso generado cumple, por tanto, las dos caracterizaciones equivalentes del proceso de Poisson: número de eventos Poisson y tiempos entre eventos exponenciales.

(b) Variable aleatoria de Coxian

Con $k = 3$, $\lambda = (1, 0.5, 2)$ y $\alpha = (0.8, 0.6, 0)$ la media teórica es $E[X] = 1 + 0.8 \cdot 2 + 0.48 \cdot 0.5 = 2.840$ y las probabilidades de completar 1, 2 y 3 etapas son 0.20, 0.32 y 0.48. Sobre 10.000 valores la media muestral fue 2.8372 y las frecuencias relativas de etapas 0.2019, 0.3169 y 0.4812. La Figura 4 compara el histograma con la densidad teórica calculada como mezcla de hipoexponenciales, cuya integral numérica es 1.0000 y cuya media es 2.8400, lo que confirma tanto el algoritmo como la deducción de la densidad. La forma resultante es la de una exponencial “engrosada” cerca del origen por el 20 % de trabajadores que abandonan tras la primera etapa y con una cola larga aportada por la segunda etapa, la más lenta ($1/\lambda_2 = 2$).




Figura 4: Histograma de 10.000 valores de la variable de Coxian frente a su densidad teórica (mezcla de hipoexponenciales).

4.5. Proceso de Poisson no homogéneo (5.3)

Con la misma semilla (777), la versión básica produjo 80 eventos a partir de 264 candidatos (aceptación 0.303) y la versión por subintervalos 71 eventos a partir de 99 candidatos (aceptación 0.717); en ambas hubo 4 eventos en $[0, 5]$. Los diez primeros tiempos de la segunda fueron 0.716, 3.082, 3.578, 4.830, 5.130, 5.785, 5.824, 5.888, 5.900 y 6.316: dispersos en $[0, 5]$ y cada vez más densos después, como corresponde a la intensidad. La Tabla 5 resume las 1000 réplicas y la Figura 5 muestra una realización y la intensidad empírica.

Método	Media $N(10)$	Var. $N(10)$	Media $N(5)$	Candidatos/réplica	Aceptación
Básico ($\lambda_{\max} = 26$)	70.188	71.588	2.538	260.88	0.269
Subintervalos (1; 13.5; 26)	69.892	71.328	2.516	103.56	0.675
Teórico	70.000	70.000	2.500	260 / 103.75	0.269 / 0.675

Tabla 5: Proceso de Poisson no homogéneo en $[0, 10]$: 1000 réplicas de cada versión del adelgazamiento frente a los valores teóricos $m(10) = 70$, $m(5) = 2.5$, $\lambda_{\max}T = 260$ y $\sum_j \lambda_j(t_j - t_{j-1}) = 103.75$.




Figura 5: Izquierda: intensidad $\lambda(t)$, eventos de una realización (marcas), $N(t)$ y $m(t) = E[N(t)]$. Derecha: intensidad empírica estimada a partir de 1000 réplicas (clases de amplitud 0,25) frente a $\lambda(t)$.

Las dos versiones generan el mismo proceso: en ambas $N(10)$ tiene media y varianza cercanas a $m(10) = 70$ (como corresponde a una Poisson(70)) y $N(5)$ media cercana a $m(5) = 2,5$, y la intensidad empírica del panel derecho reproduce la forma lineal por tramos de $\lambda(t)$, incluido el quiebre de pendiente en $t = 5$. La diferencia está en el costo: la versión básica necesita 260,9 candidatos por realización y acepta sólo el 26,9 % (en $[0, 5]$ rechaza más del 96 % de los candidatos, porque allí $\lambda(t) \leq 1$ frente a la cota 26), mientras que la versión por subintervalos necesita 103,6 candidatos y acepta el 67,5 %, es decir, 2,5 veces menos exponenciales y uniformes para el mismo resultado. Ambas tasas coinciden con las teóricas $70/260 = 0,269$ y $70/103,75 = 0,675$. El panel izquierdo muestra también que $N(t)$ se mantiene prácticamente plano en $[0, 5]$ y crece de forma cuadrática después, siguiendo a $m(t)$: en este proceso el 96 % de los eventos ocurre en la segunda mitad del horizonte.

5. Conclusiones

- El generador congruencial mixto de módulo 2^{48} superó de nuevo las pruebas de uniformidad ($\chi^2 = 13,74 < 16,92$) y aleatoriedad ($|Z| = 1,45 < 1,96$) sobre 1000 valores, y su periodo de $2,81 \times 10^{14}$ es varios órdenes de magnitud mayor que el millón de uniformes consumido en el laboratorio, por lo que cumple la condición exigida por la guía para alimentar todos los generadores.
- El método de la transformada inversa resolvió los cuatro apartados de 5.1 con una sola uniforme por valor, porque en los cuatro casos F^{-1} tiene forma cerrada: un logaritmo en (a), una raíz cuadrada por tramo en (b), la fórmula cuadrática en (c) y una potencia en (d). Las medias muestrales difirieron de las teóricas en menos de 0,022 y la prueba de Kolmogórov–Smirnov no rechazó ninguna distribución objetivo (p -valores de 0,29, 0,66, 0,52 y 0,16).
- El método del rechazo produce muestras igualmente válidas pero a un costo de c intentos por valor: resolver (b) con envolvente uniforme costó 3,83 uniformes por valor en lugar de una. Por eso sólo se justifica cuando F^{-1} no es calculable, como en la Gamma($\frac{3}{2}$) (aceptación 0,795) o la normal (aceptación 0,763); las tasas medidas coincidieron con $1/c$ en los tres casos.
- Para la normal estándar el método polar fue el más eficiente, con 1,30 uniformes por valor



frente a 3,62 del rechazo, gracias a que cada par aceptado (probabilidad $\pi/4$, observada 0,772) produce dos normales independientes sin evaluar funciones trigonométricas.

- El proceso de Poisson generado a partir de exponenciales cumplió sus dos caracterizaciones equivalentes: en 2000 réplicas $N(T)$ tuvo media 19,94 y varianza 21,73 frente a $\lambda T = 20$, con χ^2 contra Poisson(20) de $p = 0,929$, y los tiempos entre eventos tuvieron media 0,5008 con KS $p = 0,895$ contra Exp(2). La variable de Coxian reprodujo la media $\sum_i \pi_i / \lambda_i = 2,840$ (muestral 2,837), las probabilidades de abandono por etapa y la densidad teórica deducida como mezcla de hipoexponenciales.
- En el proceso de Poisson no homogéneo, el adelgazamiento básico y el adelgazamiento por subintervalos generan la misma distribución ($\bar{N}(10)$ de 70,19 y 69,89 frente a $m(10) = 70$; intensidad empírica idéntica a $\lambda(t)$), pero el segundo necesita 103,6 candidatos por realización en lugar de 260,9, un ahorro de 2,5 veces que proviene de no usar la cota global $\lambda_{\text{máx}} = 26$ en el tramo $[0, 5]$ donde $\lambda(t) \leq 1$. La lección general es que la corrección del método depende sólo de que la cota domine a $\lambda(t)$, mientras que su eficiencia depende de cuán ajustada sea esa cota.

Bibliografía

- [1] A. A. Cruz Roa, “Generación de variables aleatorias continuas,” Diapositivas del curso Simulación Computacional, Universidad de los Llanos, 2024.
- [2] S. M. Ross, *Simulation*, 5th ed. San Diego, CA: Academic Press, 2013.