Análisis de Datos de Entrada y Ajuste de Datos a Distribuciones de Probabilidad

Miguel Ángel Rincón Morales[1]

1. Cod: 160005038, Ing. Sistemas.

Facultad de Ciencias Básicas e Ingenierías. Programa de Ingeniería de Sistemas.

Fecha: 26 de Octubre de 2026

Resumen

Este informe documenta el análisis de datos de entrada de cuatro muestras de 200 observaciones (conjuntos A, B, C y D) tomadas de cuatro procesos estocásticos, siguiendo la metodología del Capítulo 3 del *Handbook of Simulation* de Banks. En la etapa descriptiva se calcularon las medidas de posición y dispersión y los histogramas de 20 clases; en la etapa de verificación de supuestos se construyeron las correlaciones de retraso, los diagramas de dispersión, el patrón de hora de llegada, el conteo de llegadas por intervalo y la media móvil de cada secuencia, complementados con las pruebas de Ljung–Box, de rachas y de Spearman. Los resultados muestran que B y D son secuencias independientes y estacionarias (Ljung–Box $p = 0{,}73$ y $p = 0{,}99$), que A es estacionaria pero autocorrelacionada ($\hat{\rho}_1 = 0{,}49$, $p < 10^{-13}$) y que C es no estacionaria, con una media que crece con el índice (Spearman $\rho = 0{,}60$, $p < 10^{-20}$) y una tasa de llegadas decreciente. En la etapa de ajuste se estimaron por máxima verosimilitud nueve distribuciones (exponencial, lognormal, normal, gamma, beta, Weibull, Rayleigh, Gumbel y gaussiana inversa) y se compararon con SSE, AIC y BIC. Las distribuciones seleccionadas fueron la normal ($\mu = 0{,}195$, $\sigma = 0{,}0437$) para A, la exponencial ($\lambda = 4{,}87$) para B, la Weibull ($c = 0{,}80$, $\beta = 676$) para C y la lognormal ($\mu_{\ln} = 0{,}241$, $\sigma_{\ln} = 1{,}019$) para D; en los cuatro casos la prueba de Kolmogórov–Smirnov no rechazó la distribución elegida.

Palabras clave — análisis de datos de entrada, estadística descriptiva, independencia, estacionariedad, correlación de retraso, bondad de ajuste, máxima verosimilitud, SSE, AIC, BIC, distribuciones de probabilidad.

1. Objetivos

- Introducir al análisis de datos de entrada en un estudio de simulación a partir de muestras de datos asociadas a procesos o fenómenos del sistema objeto de estudio.
- Identificar si un conjunto de valores de una muestra de datos asociados a algún proceso o fenómeno se puede asociar a una variable aleatoria independiente (no correlacionada) y estacionaria.
- Evaluar la bondad de ajuste (*goodness of fit*) de diferentes distribuciones de probabilidad a un conjunto de datos.
- Seleccionar la distribución de probabilidad más apropiada y con mejor ajuste dado un conjunto de datos para su posterior modelado en un estudio de simulación.

2. Consulta previa

2.1. ¿En qué consiste la estadística descriptiva?

Es la rama de la estadística que se ocupa de resumir, organizar y presentar un conjunto de datos sin pretender inferir conclusiones sobre la población de la que provienen. Sus herramientas son las medidas de posición (media, mediana, moda, percentiles), de dispersión (rango, varianza, desviación estándar, rango intercuartílico, coeficiente de variación), de forma (asimetría y curtosis) y las representaciones gráficas (histogramas, diagramas de caja, diagramas de dispersión). En un estudio de simulación es el primer paso del análisis de datos de entrada: antes de proponer una distribución conviene conocer el rango, el centro, la dispersión y la forma de la muestra, porque estas medidas ya descartan familias de distribuciones [1, 2].

2.2. ¿Qué son la asimetría estadística (*skewness*), la curtosis y los percentiles?

La **asimetría** es el tercer momento estandarizado, $\gamma_1 = E[(X-\mu)^3]/\sigma^3$, y mide la falta de simetría de la distribución respecto de su media: $\gamma_1 = 0$ en una distribución simétrica (como la normal), $\gamma_1 > 0$ cuando la cola derecha es más larga (exponencial, lognormal, gamma con forma pequeña) y $\gamma_1 < 0$ cuando lo es la izquierda. La **curtosis** es el cuarto momento estandarizado, $\gamma_2 = E[(X-\mu)^4]/\sigma^4$, y mide el peso de las colas y el apuntamiento respecto de la normal, para la cual vale 3; por eso suele reportarse el *exceso de curtosis* $\gamma_2 - 3$, positivo en distribuciones de colas pesadas (leptocúrticas) y negativo en distribuciones de colas ligeras (platicúrticas, como la uniforme). El **percentil** p es el valor x_p tal que una fracción p de las observaciones es menor o igual que él; los percentiles 25, 50 y 75 son los cuartiles Q_1, Q_2 (mediana) y Q_3, y su diferencia $Q_3 - Q_1$ es el rango intercuartílico, una medida de dispersión robusta frente a valores extremos.

2.3. ¿Qué significa y en qué consiste el supuesto de que un conjunto de variables aleatorias sean IID?

IID significa *independientes e idénticamente distribuidas*. Un conjunto $X_1, \ldots, X_n$ es IID cuando (i) todas las variables tienen la misma función de distribución F, y (ii) son mutuamente independientes, de modo que $P(X_1 \le x_1, \ldots, X_n \le x_n) = \prod_i F(x_i)$: el valor de una observación no aporta información sobre las demás. Este supuesto es el que permite estimar una única distribución a partir de la muestra y luego generar valores de ella de forma independiente en el modelo de simulación. Banks [1] lo descompone en dos verificaciones prácticas: la *independencia* (sección 3.4.1, mediante correlaciones de retraso y diagramas de dispersión) y la *estabilidad de la distribución* (sección 3.4.2, mediante patrones de llegada, conteos por intervalo y medias móviles). Cuando no se cumple, el modelo debe incorporar la dependencia o la no estacionariedad (sección 3.6).

2.4. ¿En qué consiste un proceso estocástico estacionario?

Un proceso estocástico $\{X_t\}$ es *estrictamente estacionario* si la distribución conjunta de cualquier colección $(X_{t_1}, \ldots, X_{t_k})$ es igual a la de $(X_{t_1+h}, \ldots, X_{t_k+h})$ para todo desplazamiento h: sus propiedades probabilísticas no cambian con el tiempo. En la práctica se usa la *estacionariedad débil* (o de segundo orden): media constante, $E[X_t] = \mu$; varianza constante, $\mathrm{Var}(X_t) = \sigma^2$; y covarianza que sólo depende del retardo, $\mathrm{Cov}(X_t, X_{t+k}) = \gamma_k$. Una serie con tendencia en la media, con varianza que crece con el tiempo o con una tasa de llegadas que cambia a lo largo del horizonte no es estacionaria. Nótese que un proceso puede ser estacionario y, aun así, correlacionado (por ejemplo, un proceso autorregresivo estable).

2.5. ¿En qué consiste un proceso estocástico correlacionado?

Es un proceso en el que las variables no son independientes entre sí: existe algún retardo k para el cual la *autocorrelación* $\rho_k = \gamma_k/\gamma_0$ es distinta de cero. Con $\rho_1 > 0$ los valores grandes tienden a seguir a valores grandes (la serie es "suave" y presenta menos rachas que una secuencia aleatoria); con $\rho_1 < 0$ se alternan valores altos y bajos. En simulación, tratar como IID una entrada correlacionada distorsiona la variabilidad de las salidas: por ejemplo, tiempos entre llegadas con autocorrelación positiva producen periodos de congestión más largos que los de un proceso de Poisson con la misma tasa media [1]. La herramienta básica para detectarla es el correlograma de correlaciones de retraso estimadas,

$$\hat{\rho}_k = \frac{\sum_{i=1}^{n-k}(x_i - \bar{x})(x_{i+k} - \bar{x})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}, \qquad k = 1, 2, \ldots \tag{1}$$

cuyos valores, bajo independencia, caen con probabilidad aproximada del 95 % dentro de la banda $\pm 2/\sqrt{n}$.

3. Fundamento teórico

El procedimiento sigue las diapositivas de clase *3. Input Data Analysis* [3] y el Capítulo 3 de [1]: (1) recolectar y describir los datos, (2) verificar los supuestos de independencia y estabilidad de la distribución, y (3) en el caso IID univariado, seleccionar la forma de la distribución y estimar sus parámetros, evaluando la bondad del ajuste.

3.1. Verificación de supuestos

Para la **independencia** se usan las correlaciones de retraso estimadas de la ecuación (1) y el diagrama de dispersión de pares consecutivos (x_i, x_{i+1}). Como contraste global se emplea el estadístico de Ljung–Box [4], $Q = n(n+2)\sum_{k=1}^{h}\hat{\rho}_k^2/(n-k)$, que bajo independencia se distribuye χ^2_h, y la prueba de rachas de Wald–Wolfowitz sobre la mediana. Para la **estabilidad** se interpretan los datos como tiempos entre llegadas, con tiempos de llegada $t_i = \sum_{j \le i} x_j$: el *patrón de hora de llegada* grafica el conteo acumulado $N(t)$, que es una recta de pendiente $\lambda = n/t_n$ si la tasa es constante; el *conteo de llegadas por intervalo* parte $[0, t_n]$ en intervalos iguales y cuenta las llegadas en cada uno, que deben fluctuar alrededor de un valor común; y la *media móvil* $\bar{x}_i^{(w)} = \frac{1}{w}\sum_{j=i-w+1}^{i} x_j$ revela tendencias o cambios de nivel en la media. Como contraste numérico de tendencia se usa la correlación de Spearman entre el índice i y el valor x_i.

3.2. Ajuste de distribuciones y bondad de ajuste

Los parámetros de cada distribución candidata se estiman por **máxima verosimilitud** (MLE), maximizando $\ln L(\theta) = \sum_i \ln f(x_i;\theta)$, que es el método implementado en `scipy.stats` [5] y el usado en el tutorial de [6]. La bondad del ajuste se evalúa con tres criterios:

- **SSE** (suma de errores cuadráticos) entre la densidad empírica del histograma, h_j, y la densidad ajustada en el centro c_j de cada clase:

$$\mathrm{SSE} = \sum_{j=1}^{20}\big(h_j - f(c_j;\hat{\theta})\big)^2 \tag{2}$$

  Es la medida más intuitiva, pero depende del número de clases y de su posición.

- **AIC** (criterio de información de Akaike [7]) y **BIC** (criterio bayesiano de Schwarz [8]):

$$\mathrm{AIC} = 2p - 2\ln \hat{L}, \qquad \mathrm{BIC} = p\ln n - 2\ln \hat{L} \tag{3}$$

  con p el número de parámetros estimados y n el tamaño de la muestra. Ambos premian la verosimilitud y penalizan la complejidad; el BIC penaliza más ($\ln 200 = 5{,}3 > 2$), por lo que favorece modelos más parsimoniosos. Diferencias de AIC menores que 2 entre dos modelos no constituyen evidencia relevante a favor de ninguno [2].

Como verificación complementaria de la distribución elegida se usa la prueba de Kolmogórov–Smirnov (KS), cuyo estadístico $D = \max_x |F_n(x) - F(x;\hat{\theta})|$ compara la distribución empírica con la ajustada.

4. Procedimiento o metodología

Todo el desarrollo se implementó en un único Notebook de Jupyter en Python ejecutado en Google Colab, `Lab6_160005038.ipynb`, adjunto a este informe, con `numpy`, `pandas`, `matplotlib` y `scipy.stats`. En este laboratorio no se requirió generar números aleatorios, pues todos los cálculos se hacen sobre las muestras dadas. Los cuatro archivos se cargan con `np.loadtxt`; si no están en el directorio de trabajo, el notebook los descarga desde los enlaces de Google Drive de la guía con `gdown`. Cada conjunto tiene $n = 200$ observaciones.

4.1. Estadística descriptiva e histogramas (5.1)

Para cada conjunto se calcularon el tamaño de la muestra, mínimo, máximo, media, varianza y desviación estándar muestrales (con $n-1$ en el denominador) y los percentiles 25 %, 50 % y 75 % con `np.percentile`. Se añadieron la asimetría y el exceso de curtosis (`scipy.stats.skew` y `kurtosis`) porque anticipan la familia de distribuciones candidata. Los histogramas se graficaron con 20 clases en una figura de 2×2 subgráficas.

```
def describir(x):
    q1, q2, q3 = np.percentile(x, [25, 50, 75])
    return {"Tamaño de la muestra": len(x), "Mínimo": x.min(), "Máximo": x.max()
        ,
            "Media": x.mean(), "Varianza": x.var(ddof=1),
            "Desviación estándar": x.std(ddof=1),
            "Percentil 25% (Q1)": q1, "Percentil 50% (Q2, mediana)": q2,
            "Percentil 75% (Q3)": q3,
            "Asimetría (skewness)": st.skew(x), "Curtosis (exceso)": st.kurtosis
                (x)}

tabla1 = pd.DataFrame({f"Dataset {k}": describir(x) for k, x in datos.items()})
```

Bloque de código 1: Estadística descriptiva de cada conjunto de datos.

4.2. Análisis de datos de entrada (5.2)

Siguiendo el notebook *Example. Input Data Analysis*, para cada conjunto se construyeron las cinco gráficas de la guía, cada una como figura de 2×2 subgráficas (una por conjunto): (a) correlaciones de retraso estimadas para $k = 1, \ldots, 25$ con bandas $\pm 2/\sqrt{n} = \pm 0{,}141$; (b) diagrama de dispersión de (x_i, x_{i+1}); (c) patrón de hora de llegada, $N(t)$ frente a t, con la recta de tasa constante $\lambda = n/t_n$ como referencia; (d) conteo de llegadas en 20 intervalos iguales de $[0, t_n]$, con

la línea de referencia $n/20 = 10$; (e) media móvil con ventanas de 10 y 20 observaciones sobre la serie original. Los estadísticos de apoyo (Ljung–Box con $h = 10$, rachas sobre la mediana, Spearman índice–valor y medias de las dos mitades de la serie) se programaron a mano, como muestra el Bloque de código 2.

```
def autocorr(x, max_lag=25):
    xm = x - x.mean(); den = np.sum(xm**2)
    return np.array([np.sum(xm[:-k] * xm[k:]) / den for k in range(1, max_lag +
        1)])

def ljung_box(x, h=10):
    n = len(x); r = autocorr(x, h)
    Q = n * (n + 2) * np.sum(r**2 / (n - np.arange(1, h + 1)))
    return Q, 1 - st.chi2.cdf(Q, h)

def runs_test(x):              # rachas por encima/debajo de la mediana
    s = x > np.median(x); n1, n2 = s.sum(), (~s).sum()
    R = 1 + np.sum(s[1:] != s[:-1])
    mu = 1 + 2 * n1 * n2 / (n1 + n2)
    var = 2*n1*n2*(2*n1*n2 - n1 - n2) / ((n1 + n2)**2 * (n1 + n2 - 1))
    Z = (R - mu) / math.sqrt(var)
    return R, Z, 2 * (1 - st.norm.cdf(abs(Z)))

# (c) patrón de llegada y (d) conteos por intervalo
t = np.cumsum(x)                                  # tiempos de llegada
bordes = np.linspace(0, t[-1], 21)
conteos, _ = np.histogram(t, bins=bordes)
# (e) media móvil
mm10 = pd.Series(x).rolling(10).mean(); mm20 = pd.Series(x).rolling(20).mean()
```

Bloque de código 2: Correlaciones de retraso, prueba de Ljung–Box y prueba de rachas.

4.3. Ajuste de curvas (5.3)

Tomando como referencia el tutorial de [6], se ajustaron las cinco distribuciones de la guía — exponencial, lognormal, normal, gamma y beta— y cuatro adicionales elegidas para cubrir formas distintas: **Weibull** (cola derecha con forma flexible, muy usada en tiempos de servicio y de falla), **Rayleigh** (caso particular de Weibull con $c = 2$), **Gumbel** (valor extremo tipo I, asimétrica con soporte en toda la recta) y **gaussiana inversa** o de Wald (cola derecha pesada, alternativa a la lognormal). Cada una se ajustó por MLE con `dist.fit`. Como los datos son magnitudes no negativas (tiempos entre llegadas), en las distribuciones de soporte $[loc, \infty)$ se fijó $loc = 0$ y se estimaron sólo los parámetros de forma y escala; la normal y la Gumbel se ajustaron con posición y escala libres. Esta decisión se tomó tras una primera corrida con todos los parámetros libres, que produjo ajustes degenerados: una Weibull con $loc > \min x$ (verosimilitud nula, AIC infinito), una lognormal con $\sigma \to 0$ y $loc \to -16\,000$ que imitaba a una normal, y una gamma con forma 0,008 en el conjunto C. Con $loc = 0$ el número de parámetros p es 1 para la exponencial y la Rayleigh, 2 para la normal, Gumbel, lognormal, gamma, Weibull y gaussiana inversa, y 3 para la beta.

Para cada distribución se calcularon SSE (ecuación (2), con el mismo histograma de 20 clases), AIC y BIC (ecuación (3)). Para identificar las tres mejores se usó un *puntaje* igual a la suma de los puestos (1 a 9) que ocupa cada distribución en SSE, en AIC y en BIC; los empates se resolvieron por AIC. Las tres mejores se superpusieron al histograma en una misma figura y se verificaron con la prueba KS.

```python
DISTRIBUCIONES = {"Exponencial": st.expon, "Lognormal": st.lognorm, "Normal": st
    .norm,
                  "Gamma": st.gamma, "Beta": st.beta, "Weibull": st.weibull_min,
                  "Rayleigh": st.rayleigh, "Gumbel": st.gumbel_r,
                  "Gaussiana inversa": st.invgauss}
SOPORTE_POSITIVO = {"Exponencial", "Lognormal", "Gamma", "Beta", "Weibull",
                    "Rayleigh", "Gaussiana inversa"}

def ajustar(x, dist, nombre):
    params = dist.fit(x, floc=0) if nombre in SOPORTE_POSITIVO else dist.fit(x)
    p = len(params) - (1 if nombre in SOPORTE_POSITIVO else 0)   # parametros
        libres
    h, bordes = np.histogram(x, bins=20, density=True)
    centros = (bordes[:-1] + bordes[1:]) / 2
    sse = np.sum((h - dist.pdf(centros, *params)) ** 2)
    logL = np.sum(dist.logpdf(x, *params)); n = len(x)
    return params, sse, 2*p - 2*logL, p*math.log(n) - 2*logL

# ranking combinado: suma de puestos en SSE, AIC y BIC (menor es mejor)
df["Puntaje"] = df["SSE"].rank() + df["AIC"].rank() + df["BIC"].rank()
df = df.sort_values(["Puntaje", "AIC"])
```

Bloque de código 3: Ajuste por máxima verosimilitud y cálculo de SSE, AIC y BIC.

5. Resultados y análisis

5.1. Estadística descriptiva e histogramas (5.1)

La Tabla 1 resume las medidas descriptivas y la Figura 1 muestra los histogramas de 20 clases.

Medida estadística	Dataset A	Dataset B	Dataset C	Dataset D
Tamaño de la muestra	200	200	200	200
Mínimo	0.0210	0.0001	0.9267	0.1115
Máximo	0.2990	1.5513	6 669.85	17.9670
Media	0.1950	0.2054	762.3938	2.0605
Varianza	0.0019	0.0525	852 169.66	5.4130
Desviación estándar	0.0438	0.2291	923.1304	2.3266
Percentil 25 % (Q1)	0.1638	0.0463	152.9121	0.6343
Percentil 50 % (Q2 o mediana)	0.1921	0.1377	455.5576	1.4064
Percentil 75 % (Q3)	0.2301	0.2902	1 028.59	2.5289
Coeficiente de variación $s/\bar{x}$	0.2246	1.1154	1.2108	1.1291
Asimetría (*skewness*)	−0,2895	2.4064	2.4821	3.1596
Curtosis (exceso)	0.3090	7.9741	9.1009	14.0891

Tabla 1: Descripción estadística de los conjuntos de datos A, B, C y D. Las tres últimas filas son medidas adicionales a las solicitadas en la guía.

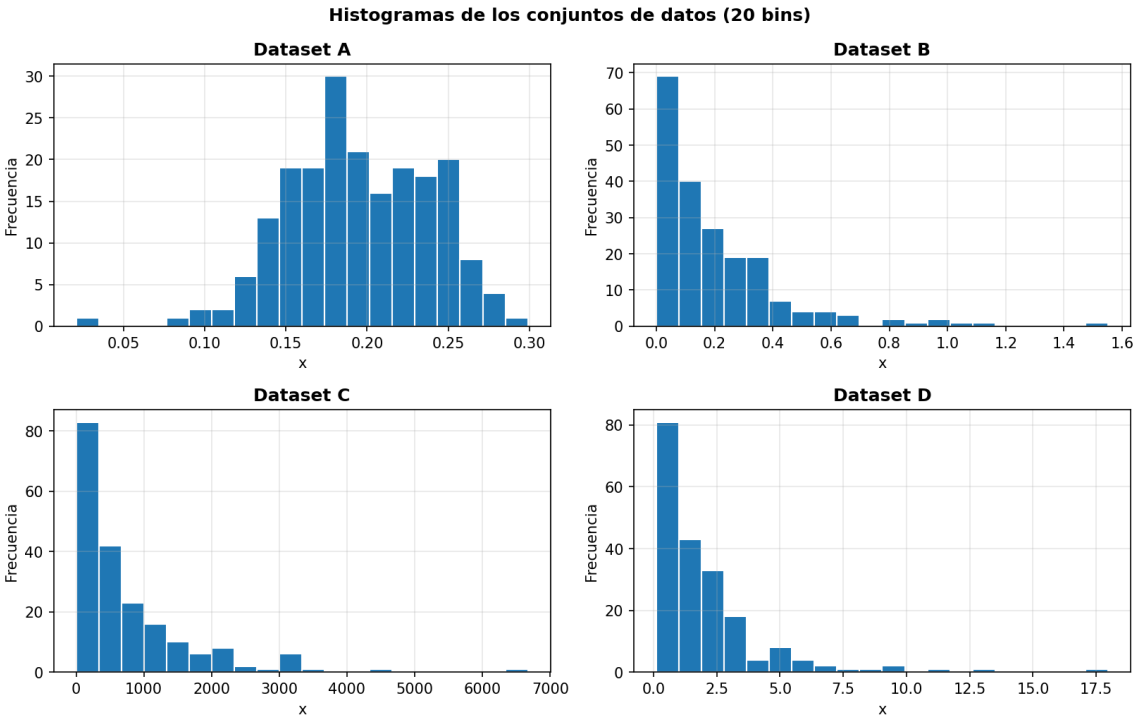


Figura 1: Histogramas de distribuciones de los conjuntos de datos A, B, C y D (20 clases).

Análisis. Las medidas y los histogramas separan los cuatro conjuntos en dos grupos claramente distintos. El **conjunto A** tiene una distribución concentrada entre 0,10 y 0,30, con media 0,195 casi igual a la mediana 0,192, asimetría prácticamente nula ($-0{,}29$), exceso de curtosis cercano a cero (0,31) y un coeficiente de variación de sólo 0,22: es la forma de campana simétrica de una normal (o de una distribución acotada casi simétrica como una beta con $a \approx b$); la exponencial queda descartada desde ya porque su coeficiente de variación es exactamente 1. Los **conjuntos B, C y D** son, en cambio, fuertemente asimétricos a la derecha (asimetría entre 2,4 y 3,2), con media mayor que la mediana (B: 0,205 frente a 0,138; D: 2,06 frente a 1,41), colas pesadas (exceso de curtosis entre 8 y 14) y coeficiente de variación próximo a 1 (1,12, 1,21 y 1,13), que es la firma de la familia exponencial y de sus generalizaciones (gamma, Weibull, lognormal). En B y C la moda del histograma está en la primera clase, pegada a cero, como en una exponencial o en una gamma/Weibull con forma menor que 1; en D la primera clase también es la más alta, pero el descenso es más gradual y el mínimo (0,11) está más lejos de cero en términos relativos, lo que deja abierta la lognormal. El **conjunto C** se distingue por su escala: valores entre 0,93 y 6 670 con desviación estándar 923, mayor que la media 762, y con $Q_3 - Q_1 \approx 876$; su histograma es idéntico en forma al de B, pero la varianza enorme y, como se verá en la sección siguiente, el crecimiento de los valores con el índice indican que no proviene de un proceso estable. Por último, cabe notar que los histogramas de la guía (Figura 1 del documento) corresponden a otros datos de ejemplo; los de la Figura 1 son los de los archivos descargados.

5.2. Análisis de datos de entrada: independencia y estacionariedad (5.2)

Las Figuras 2 a 6 presentan las cinco gráficas de la guía y la Tabla 2 los estadísticos de apoyo.

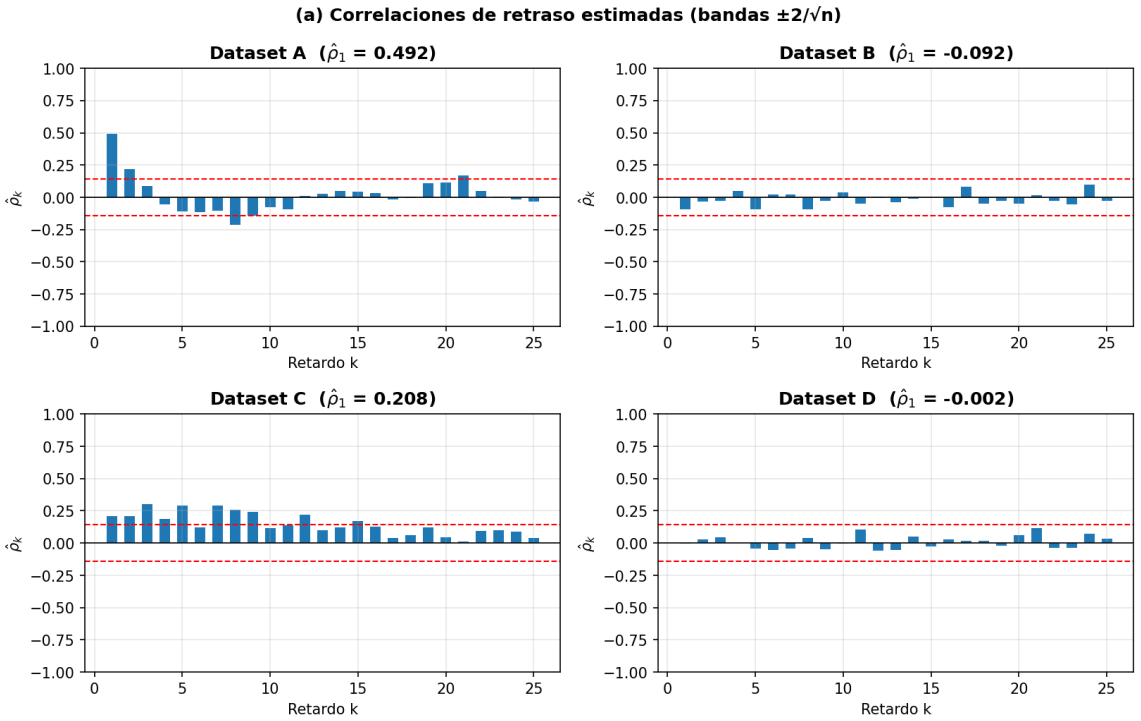


Figura 2: (a) Correlaciones de retraso estimadas $\hat{\rho}_k$, $k = 1, \ldots, 25$, con las bandas $\pm 2/\sqrt{n} = \pm 0{,}141$ (líneas rojas).

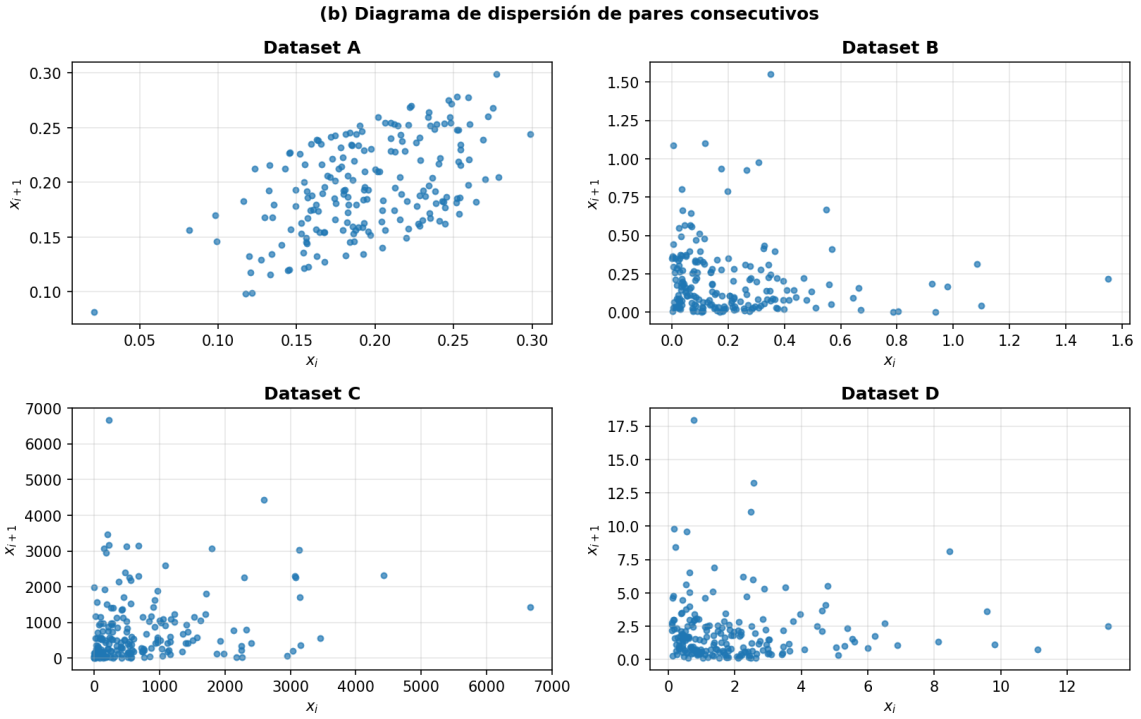


Figura 3: (b) Diagrama de dispersión de pares consecutivos (x_i, x_{i+1}).

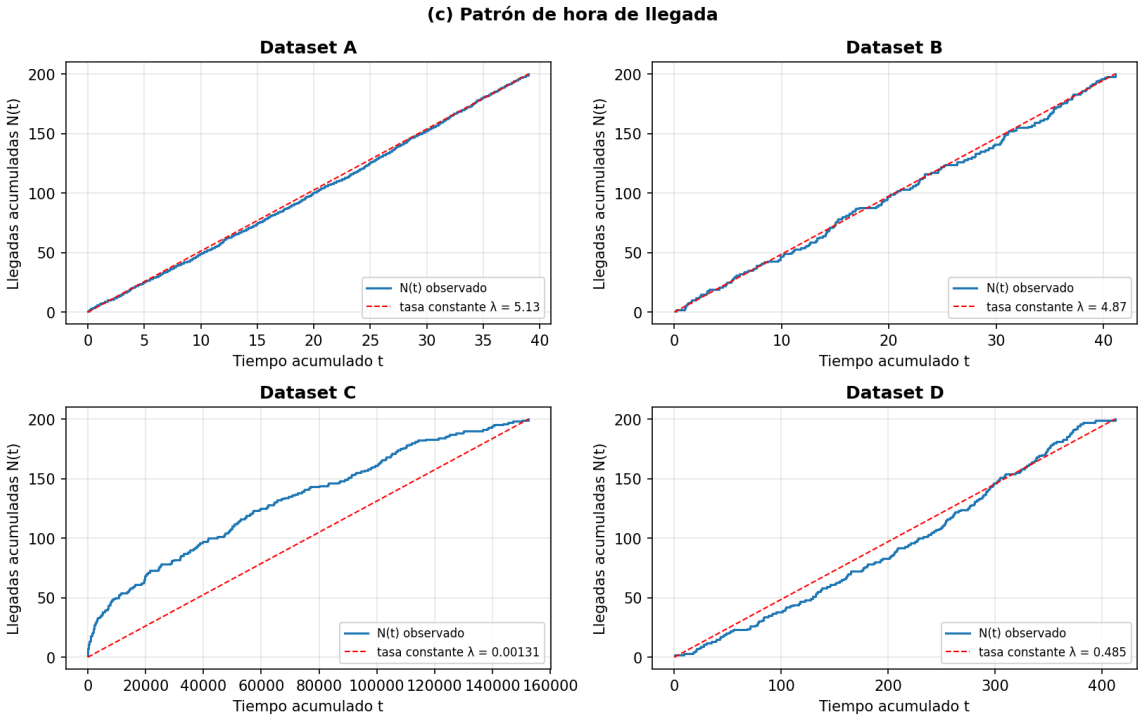


Figura 4: (c) Patrón de hora de llegada: llegadas acumuladas $N(t)$ interpretando cada x_i como tiempo entre llegadas, frente a la recta de tasa constante $\lambda = n/t_n$.

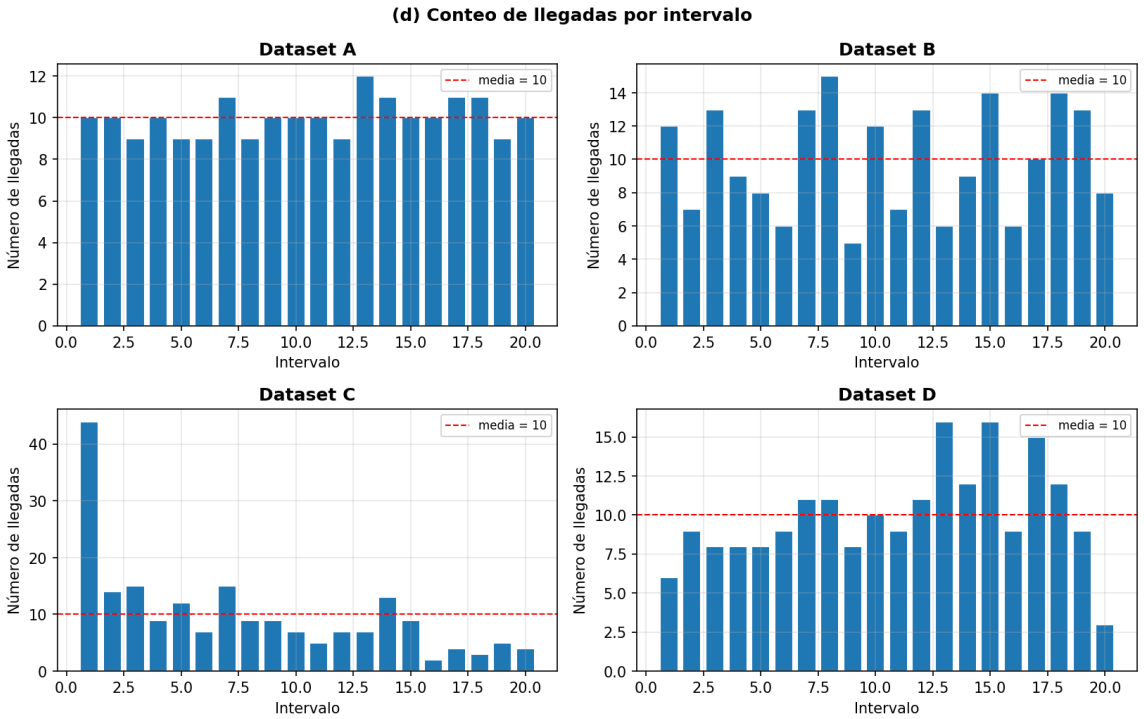


Figura 5: (d) Conteo de llegadas en 20 intervalos iguales del horizonte $[0, t_n]$; la línea roja es el promedio $n/20 = 10$.

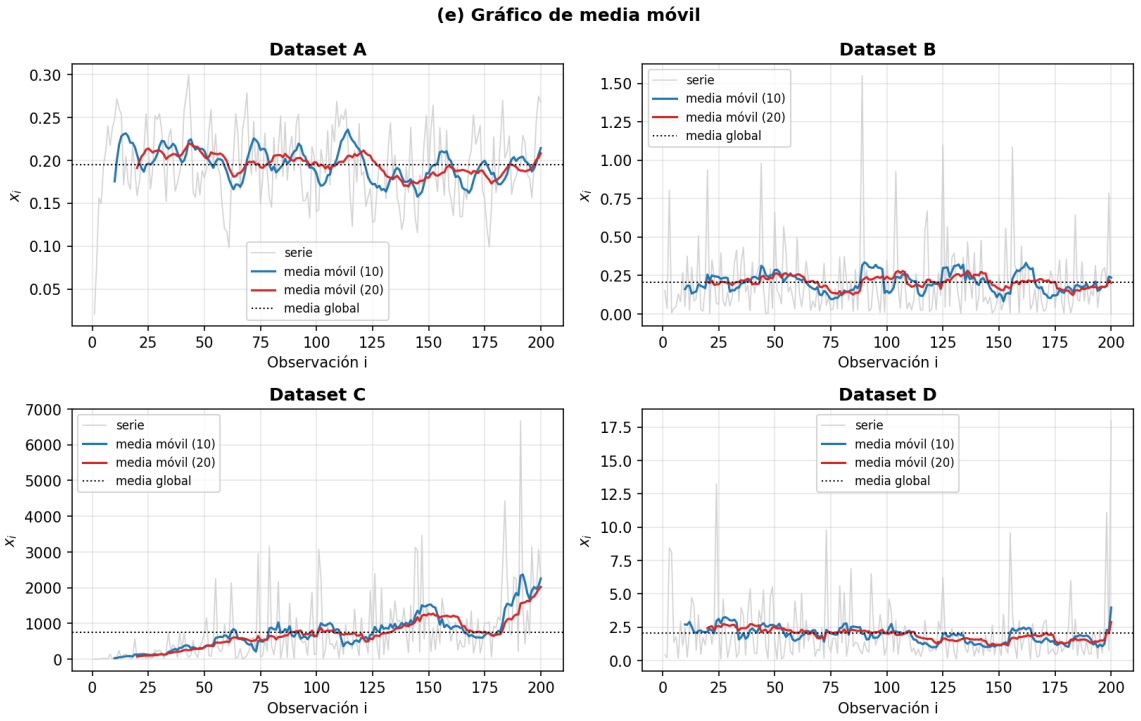


Figura 6: (e) Gráfico de media móvil con ventanas de 10 y 20 observaciones sobre la serie original (gris).

Conjunto	$\hat{\rho}_1$	Fuera de banda	LB Q_{10}	LB p	Rachas Z	Rachas p	Spearman ρ	Spearman p	$\bar{x}$ 1.ª mitad	$\bar{x}$ 2.ª mitad
Dataset A	0.492	5/25	83.7	$9{,}4 \times 10^{-14}$	−3,26	0.0011	−0,105	0.140	0.1988	0.1913
Dataset B	−0,092	0/25	6.9	0.731	2.13	0.0334	−0,003	0.961	0.2050	0.2058
Dataset C	0.208	10/25	110.9	$< 10^{-16}$	−2,41	0.0159	0.603	$3{,}2 \times 10^{-21}$	417.6	1107.2
Dataset D	−0,002	0/25	2.7	0.987	1.28	0.202	−0,117	0.099	2.283	1.838

Tabla 2: Estadísticos de independencia y estacionariedad: correlación de retardo 1, número de $\hat{\rho}_k$ fuera de la banda $\pm 2/\sqrt{n}$, prueba de Ljung–Box con 10 retardos, prueba de rachas sobre la mediana, correlación de Spearman entre el índice y el valor (tendencia) y media de cada mitad de la serie.

Dataset A: estacionario pero correlacionado. El correlograma muestra $\hat{\rho}_1 = 0{,}49$ y $\hat{\rho}_2 = 0{,}21$, muy por encima de la banda, con un decaimiento aproximadamente geométrico típico de un proceso autorregresivo de primer orden; cinco retardos salen de la banda y Ljung–Box rechaza la independencia de forma contundente ($Q_{10} = 83{,}7$, $p < 10^{-13}$). El diagrama de dispersión lo confirma: los pares (x_i, x_{i+1}) se alinean a lo largo de la diagonal, y la prueba de rachas encuentra sólo 78 rachas frente a las ≈ 101 esperadas ($Z = -3{,}26$), es decir, los valores altos se agrupan con valores altos y los bajos con bajos. En cambio, la serie es **estacionaria**: la media móvil oscila alrededor de la media global sin tendencia (Spearman $p = 0{,}14$; medias de las mitades 0,199 y 0,191), $N(t)$ es una recta casi perfecta y los conteos por intervalo están todos entre 9 y 12 —una dispersión incluso menor que la de un proceso de Poisson, consecuencia del bajo coeficiente de variación–. En consecuencia, A no cumple el supuesto IID por falta de independencia; para simularlo habría que modelar la dependencia (sección 3.6 de [1], por ejemplo con un proceso AR(1) o un proceso ARTA con marginal normal) y no basta con muestrear de su distribución marginal.

Dataset B: independiente y estacionario. Ninguna de las 25 correlaciones de retraso sale de la banda ($\hat{\rho}_1 = -0{,}09$) y Ljung–Box no rechaza la independencia ($p = 0{,}73$). El diagrama de dispersión es una nube sin estructura concentrada cerca del origen (por la asimetría de la distribución). La prueba de rachas da $Z = 2{,}13$ ($p = 0{,}033$): hay algo más de rachas de las esperadas, lo que sugiere una ligera alternancia que, sin embargo, no se refleja en el correlograma; con tres pruebas por conjunto un p-valor aislado de este tamaño es compatible con el azar y no se considera evidencia de dependencia. La estabilidad es clara: $N(t)$ coincide con la recta de tasa $\lambda = 4{,}87$, los conteos por intervalo fluctúan entre 5 y 15 alrededor de 10 (la dispersión esperable en una Poisson de media 10) y las medias de las dos mitades son 0,2050 y 0,2058. B puede tratarse como una muestra IID.

Dataset C: no estacionario. Es el caso opuesto. La media móvil crece de valores cercanos a 30 al inicio hasta más de 2 000 al final; la media de la segunda mitad (1 107) casi triplica la de la primera (418) y la varianza también se triplica; la correlación de Spearman entre el índice y el valor es 0,60 ($p < 10^{-20}$). Esta tendencia produce 10 correlaciones de retraso fuera de la banda, todas positivas y sin decaer (una serie con tendencia siempre aparece correlacionada), y rechazos de Ljung–Box y de rachas, pero el origen del problema no es la dependencia de corto plazo sino el cambio de nivel. Leído como proceso de llegadas, $N(t)$ es cóncavo: las primeras 100 llegadas ocurren en el 27 % del horizonte y el primer intervalo del conteo recibe 44 llegadas mientras que los últimos cinco reciben entre 2 y 5; la tasa de llegadas decrece con el tiempo. Por tanto C no es estacionario y no cumple el supuesto IID; un modelo de simulación debería representarlo con una tasa dependiente del tiempo (por ejemplo un proceso de Poisson no homogéneo) o con una tendencia explícita, tal como sugiere la sección 3.6 de [1]. El ajuste de una sola distribución a estos datos, que se hace en la sección siguiente por exigencia de la guía, sólo describe la mezcla de todos los niveles y no serviría para predecir el comportamiento futuro del proceso.

Dataset D: independiente y estacionario. Es el conjunto que mejor cumple los supuestos: todas las correlaciones de retraso están dentro de la banda ($\hat{\rho}_1 = -0{,}002$), Ljung–Box da $p = 0{,}99$ y la prueba de rachas $p = 0{,}20$; el diagrama de dispersión no muestra estructura. La media móvil presenta una leve disminución hacia el final (medias de las mitades 2,28 y 1,84), que se traduce en conteos por intervalo algo mayores en la segunda mitad del horizonte (hasta 16), pero la correlación de Spearman no es significativa ($\rho = -0{,}12$, $p = 0{,}10$) y $N(t)$ se mantiene cerca de la recta de tasa $\lambda = 0{,}485$; con 200 observaciones de una distribución tan asimétrica esa variación es compatible con el muestreo. D puede tratarse como una muestra IID.

5.3. Ajuste de curvas y bondad de ajuste (5.3)

Las Tablas 3 a 6 muestran, para cada conjunto, los parámetros estimados por MLE (`loc`, `esc` = escala y los parámetros de forma con el nombre que usa `scipy`) y las tres métricas; las tres mejores distribuciones según el puntaje combinado se resaltan en negrita. La Figura 7 superpone esas tres distribuciones al histograma de cada conjunto y la Figura 8 muestra las nueve a la vez. La Tabla 7 recoge la prueba KS de las tres mejores.

Distribución	Parámetros	SSE	AIC	BIC	Puntaje
Exponencial	loc=0, esc=0.195	340.471	-251.82	-248.52	27
Lognormal	s=0.275, loc=0, esc=0.189	36.974	-611.09	-604.49	17
Normal	loc=0.195, esc=0.0437	29.148	-680.59	-673.99	5
Gamma	a=16.18, loc=0, esc=0.01206	28.239	-647.34	-640.75	10
Beta	a=14.49, b=76.15, loc=0, esc=1.217	27.110	-651.75	-641.85	7
Weibull	c=5.071, loc=0, esc=0.212	32.427	-679.36	-672.76	8
Rayleigh	loc=0, esc=0.1413	185.201	-497.00	-493.70	24
Gumbel	loc=0.1728, esc=0.0491	42.531	-620.45	-613.85	16
Gaussiana inversa	mu=0.08962, loc=0, esc=2.176	48.059	-583.42	-576.83	21

Tabla 3: Bondad de ajuste para el conjunto de datos A.

Distribución	Parámetros	SSE	AIC	BIC	Puntaje
Exponencial	loc=0, esc=0.2054	0.436	-231.13	-227.83	8
Lognormal	s=1.437, loc=0, esc=0.104	2.326	-188.73	-182.14	15
Normal	loc=0.2054, esc=0.2285	11.570	-18.89	-12.29	22
Gamma	a=0.8636, loc=0, esc=0.2378	0.316	-232.10	-225.50	7
Beta	a=0.8636, b=1.352e+12, loc=0, esc=3.215e+11	0.316	-230.10	-220.20	11
Weibull	c=0.9095, loc=0, esc=0.1963	0.276	-232.26	-225.67	4
Rayleigh	loc=0, esc=0.2173	18.125	85.99	89.29	25
Gumbel	loc=0.1171, esc=0.132	5.729	-138.45	-131.85	18
Gaussiana inversa	mu=22.4, loc=0, esc=0.009169	6.528	151.99	158.58	25

Tabla 4: Bondad de ajuste para el conjunto de datos B.

Distribución	Parámetros	SSE	AIC	BIC	Puntaje
Exponencial	loc=0, esc=762.4	5.978e-08	3056.59	3059.88	12
Lognormal	s=1.648, loc=0, esc=324.3	6.361e-08	3084.19	3090.78	15
Normal	loc=762.4, esc=920.8	9.265e-07	3301.68	3308.28	22
Gamma	a=0.7062, loc=0, esc=1080	4.493e-08	3040.22	3046.82	5
Beta	a=0.712, b=6.036e+05, loc=0, esc=6.462e+08	4.442e-08	3042.23	3052.13	8
Weibull	c=0.8007, loc=0, esc=676	2.524e-08	3040.81	3047.41	5
Rayleigh	loc=0, esc=845.3	1.434e-06	3481.09	3484.39	27
Gumbel	loc=409.7, esc=515.2	4.557e-07	3175.64	3182.24	19
Gaussiana inversa	mu=19.81, loc=0, esc=38.49	3.224e-07	3310.51	3317.11	22

Tabla 5: Bondad de ajuste para el conjunto de datos C. Los valores de SSE son pequeños porque la densidad del histograma es del orden de 10^{-3} (rango de los datos $\approx 6\,700$).

Distribución	Parámetros	SSE	AIC	BIC	Puntaje
Exponencial	loc=0, esc=2.06	9.898e-03	691.18	694.48	9
Lognormal	s=1.019, loc=0, esc=1.273	6.913e-03	675.89	682.49	3
Normal	loc=2.06, esc=2.321	0.117	908.33	914.93	24
Gamma	a=1.178, loc=0, esc=1.749	0.010	689.97	696.56	11
Beta	a=1.165, b=2.071e+06, loc=0, esc=3.663e+06	0.010	691.98	701.88	14
Weibull	c=1.042, loc=0, esc=2.099	0.011	692.55	699.14	16
Rayleigh	loc=0, esc=2.194	0.157	934.06	937.36	27
Gumbel	loc=1.228, esc=1.216	0.049	756.07	762.67	21
Gaussiana inversa	mu=1.763, loc=0, esc=1.169	0.025	685.40	692.00	10

Tabla 6: Bondad de ajuste para el conjunto de datos D.

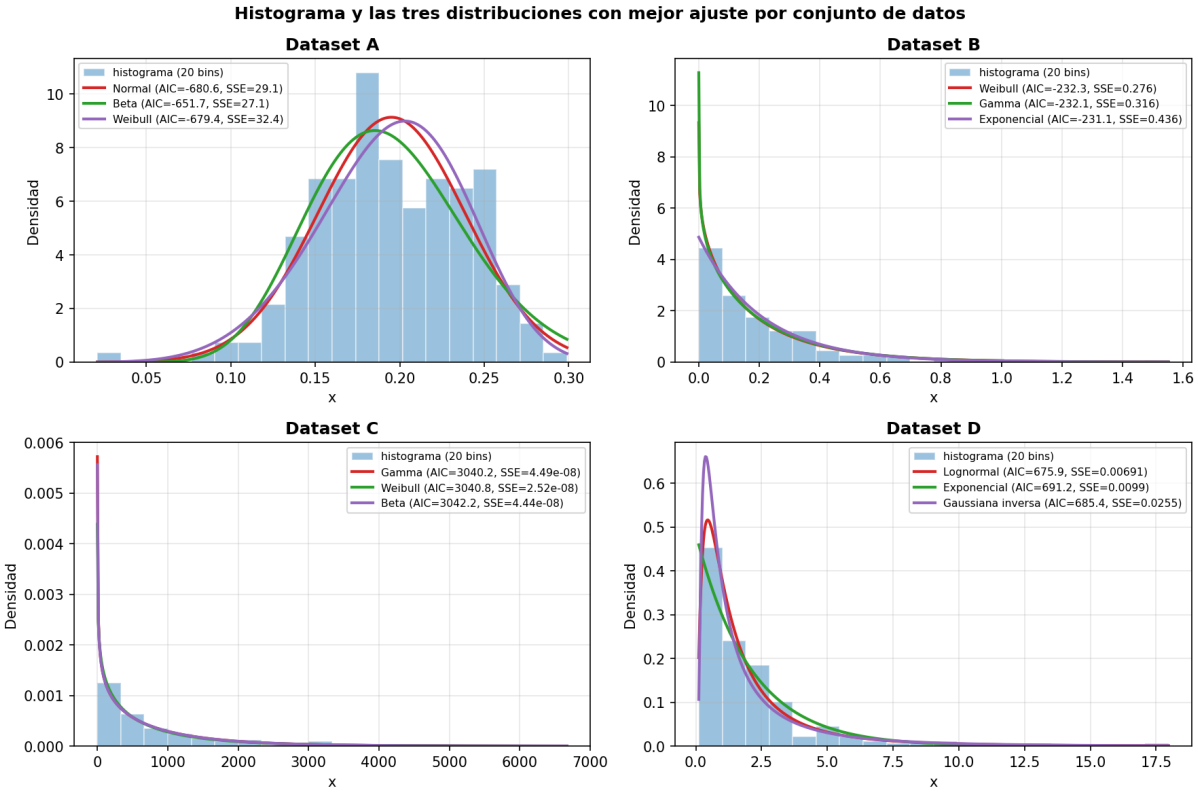


Figura 7: Histograma (densidad) de cada conjunto de datos con las tres distribuciones de mejor ajuste según el puntaje combinado de SSE, AIC y BIC.

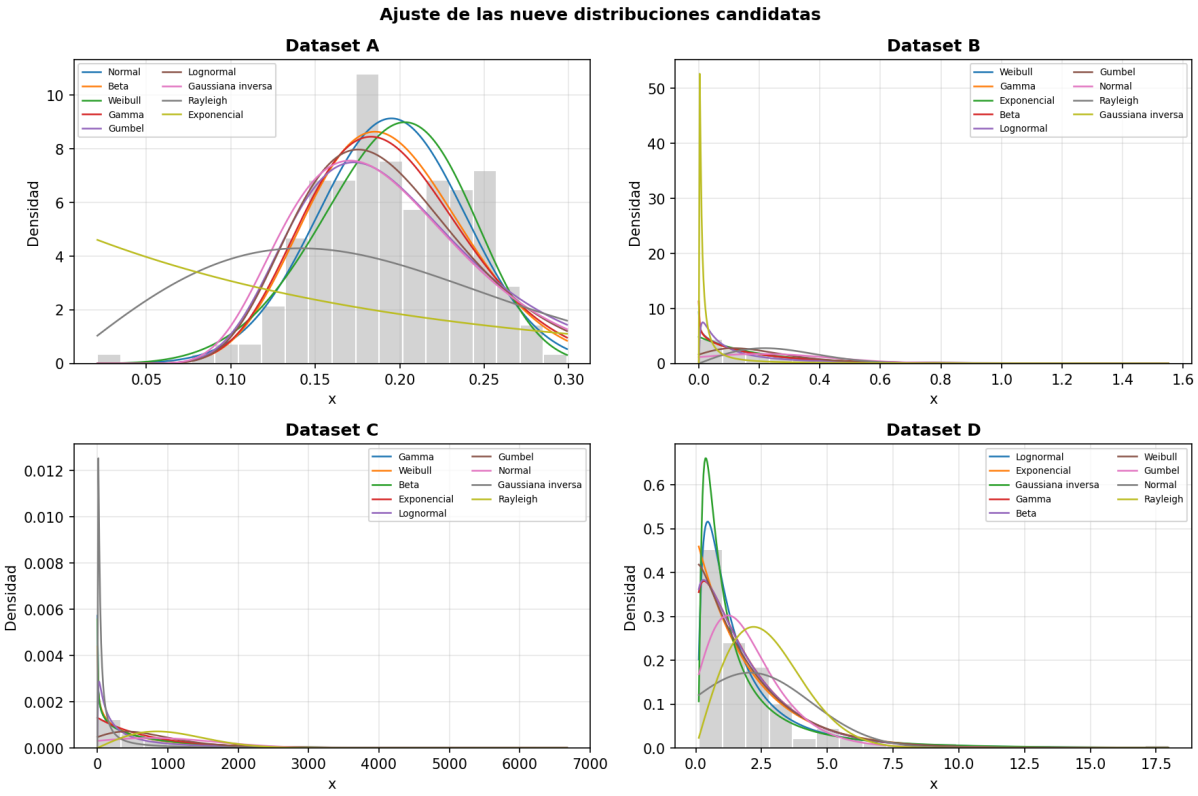


Figura 8: Las nueve distribuciones candidatas ajustadas sobre el histograma de cada conjunto de datos.

Conjunto	Distribución	KS D	KS p-valor
A	Normal	0.052	0.626
A	Beta	0.051	0.653
A	Weibull	0.068	0.292
B	Weibull	0.035	0.960
B	Gamma	0.036	0.949
B	Exponencial	0.066	0.336
C	Gamma	0.039	0.913
C	Weibull	0.037	0.941
C	Beta	0.040	0.897
D	Lognormal	0.054	0.591
D	Exponencial	0.064	0.372
D	Gaussiana inversa	0.092	0.062

Tabla 7: Prueba de Kolmogórov–Smirnov de las tres mejores distribuciones de cada conjunto ($\alpha = 0{,}05$; ninguna se rechaza).

Observaciones generales. En B, C y D la distribución beta converge a un parámetro b del orden de 10^6 a 10^{12} con escala igualmente enorme: como los datos no están acotados, la beta "escapa" hacia su límite gamma ($\text{Beta}(a,b)\cdot s \to \text{Gamma}(a, s/b)$ cuando $b \to \infty$) y reproduce exactamente el ajuste de la gamma con un parámetro más, por lo que siempre queda detrás de ella

en AIC y BIC. Sólo en A, cuyos valores viven en un intervalo estrecho, la beta obtiene un ajuste propio (soporte [0; 1,217]) y el menor SSE. También se observa que SSE no siempre coincide con AIC/BIC (por ejemplo, en C la Weibull tiene la mitad del SSE de la gamma pero AIC ligeramente mayor), porque SSE sólo mira 20 puntos de la densidad y depende de la partición, mientras que la verosimilitud usa las 200 observaciones; por eso la selección se basa primordialmente en AIC y BIC y se usa SSE como criterio de apoyo.

Dataset A. Las tres mejores son la **normal** ($\mu = 0{,}195$, $\sigma = 0{,}0437$), la beta ($a = 14{,}5$, $b = 76{,}2$, escala 1,217) y la Weibull ($c = 5{,}07$, $\beta = 0{,}212$). Se selecciona la **normal**: tiene el mejor AIC ($-680{,}6$) y el mejor BIC ($-674{,}0$), con sólo dos parámetros, y el mejor KS ($p = 0{,}63$); la Weibull está a $\Delta\text{AIC} = 1{,}2$ (indistinguible estadísticamente) pero su forma $c = 5$ se usa justamente para aproximar una campana, y la beta, aunque logra el menor SSE, paga su tercer parámetro con 29 unidades más de AIC. La normal es además coherente con la asimetría ≈ 0 y el exceso de curtosis ≈ 0 de la Tabla 1. Su único inconveniente teórico —admite valores negativos— es irrelevante aquí: con $\mu/\sigma = 4{,}5$, $P(X < 0) \approx 4 \times 10^{-6}$. Debe recordarse, sin embargo, que A está autocorrelacionado: la normal describe bien la distribución *marginal*, pero en la simulación los valores deberían generarse con un modelo que conserve $\rho_1 \approx 0{,}49$.

Dataset B. Las tres mejores son la Weibull ($c = 0{,}91$, $\beta = 0{,}196$), la gamma ($a = 0{,}86$, $\beta = 0{,}238$) y la **exponencial** ($\beta = 0{,}2054$, $\lambda = 4{,}87$). Las tres tienen AIC en un rango de 1,1 unidades ($-232{,}3$, $-232{,}1$ y $-231{,}1$), es decir, los datos no distinguen entre ellas; y el BIC, que penaliza más la complejidad, prefiere la exponencial ($-227{,}8$ frente a $-225{,}7$ y $-225{,}5$). Los parámetros de forma de la Weibull ($c = 0{,}91$) y de la gamma ($a = 0{,}86$) están ambos próximos a 1, valor en el que las dos familias se reducen exactamente a la exponencial, y el coeficiente de variación muestral (1,12) es el de una exponencial. Por parsimonia se selecciona la **exponencial con media** 0,2054 ($\lambda = 4{,}87$): tiene un solo parámetro, KS $p = 0{,}34$, es la distribución natural de los tiempos entre llegadas de un proceso de Poisson (y B resultó independiente y estacionario), carece de memoria y se genera con una sola uniforme por transformada inversa.

Dataset C. Las tres mejores son la gamma ($a = 0{,}706$, $\beta = 1\,080$), la **Weibull** ($c = 0{,}80$, $\beta = 676$) y la beta (degenerada a la gamma). Gamma y Weibull empatan en puntaje (5) y difieren en AIC en 0,6 y en BIC en 0,6 unidades, sin significado estadístico; la Weibull tiene un SSE 44 % menor, el mejor KS ($p = 0{,}94$) y una ventaja práctica: su inversa tiene forma cerrada, $X = \beta(-\ln U)^{1/c}$, mientras que la gamma con forma no entera requiere un método de rechazo. Por eso, si se debe elegir una sola distribución para estos datos, se selecciona la **Weibull**($c = 0{,}80$, $\beta = 676$). La forma $c < 1$ (tasa de riesgo decreciente) refleja la mezcla de tiempos cortos del inicio de la serie con tiempos muy largos del final. Pero la respuesta de fondo es la de la sección 5.2: C no es estacionario, de modo que ninguna distribución fija lo representa adecuadamente y el modelo de simulación debería usar una tasa de llegadas que decrece con el tiempo.

Dataset D. Las tres mejores son la **lognormal** ($\sigma_{\ln} = 1{,}019$, escala $e^{\mu_{\ln}} = 1{,}273$, es decir $\mu_{\ln} = 0{,}241$), la exponencial ($\beta = 2{,}06$) y la gaussiana inversa ($\mu = 1{,}76$, $\beta = 1{,}169$). A diferencia de B, aquí la evidencia es nítida: la lognormal tiene el mejor SSE, el mejor AIC (675,9) y el mejor BIC (682,5), con $\Delta\text{AIC} = 9{,}5$ frente a la gaussiana inversa y 15,3 frente a la exponencial, diferencias que ya son concluyentes (un $\Delta\text{AIC} > 10$ equivale a una razón de verosimilitudes mayor que 150). El histograma lo explica: la densidad empírica no decrece desde $x = 0$ como la exponencial, sino que sube hasta una moda cercana a 0,5 y luego cae con cola larga, que es exactamente la forma lognormal (la gaussiana inversa también la tiene, pero ajusta peor

la cola y su KS, $p = 0{,}06$, está al borde del rechazo). Se selecciona la **lognormal** con $\mu_{\ln} = 0{,}241$ y $\sigma_{\ln} = 1{,}019$ (KS $p = 0{,}59$); como D resultó independiente y estacionario, puede muestrearse directamente de esta distribución en el modelo, generando $X = e^{\mu_{\ln} + \sigma_{\ln} Z}$ con Z normal estándar.

6. Conclusiones

- La estadística descriptiva ya orienta la elección de la familia de distribuciones: el conjunto A, con asimetría y exceso de curtosis cercanos a cero y coeficiente de variación 0,22, apunta a una campana simétrica; B, C y D, con asimetría entre 2,4 y 3,2, colas pesadas y coeficiente de variación próximo a 1, apuntan a la familia exponencial y sus generalizaciones.
- Las gráficas de la sección 3.4 de Banks permiten separar dos supuestos distintos. A es estacionario (media móvil plana, $N(t)$ lineal, conteos por intervalo entre 9 y 12) pero **correlacionado** ($\hat{\rho}_1 = 0{,}49$, Ljung–Box $p < 10^{-13}$, 78 rachas frente a 101 esperadas); C está **no estacionario** (la media de la segunda mitad triplica la de la primera, Spearman $\rho = 0{,}60$, $N(t)$ cóncavo con 44 llegadas en el primer intervalo y menos de 5 en los últimos); B y D son independientes y estacionarios (Ljung–Box $p = 0{,}73$ y $0{,}99$) y cumplen el supuesto IID.
- Ajustar con todos los parámetros libres de `scipy` produce soluciones degeneradas (posición mayor que el mínimo, verosimilitud nula; lognormal que imita a una normal). Fijar $loc = 0$ en las distribuciones de soporte positivo, coherente con la naturaleza de los datos, da estimaciones interpretables y comparables. También se comprobó que la beta, en datos no acotados, degenera en la gamma y queda siempre penalizada por su parámetro extra.
- SSE, AIC y BIC coinciden en lo esencial pero no son equivalentes: SSE depende de la partición del histograma y puede invertir el orden entre modelos cercanos (Weibull frente a gamma en C), y el BIC, con penalización $\ln 200 = 5{,}3$ por parámetro, favorece la exponencial sobre la Weibull y la gamma en B aunque el AIC las empate. Por eso el criterio de selección combinó los tres y, en caso de empate, aplicó parsimonia y facilidad de generación.
- Las distribuciones seleccionadas fueron: **A**, normal(0,195; 0,0437); **B**, exponencial con media 0,2054 ($\lambda = 4{,}87$); **C**, Weibull($c = 0{,}80$, $\beta = 676$); **D**, lognormal($\mu_{\ln} = 0{,}241$, $\sigma_{\ln} = 1{,}019$). En los cuatro casos la prueba KS no rechaza la distribución elegida (p entre 0,34 y 0,94). Sólo en B y D la distribución puede usarse directamente como entrada IID del modelo; en A debe acompañarse de un modelo de dependencia serial y en C debe reemplazarse por un modelo con tasa dependiente del tiempo, de acuerdo con la sección 3.6 de [1].

Bibliografía

[1] J. Banks, *Handbook of Simulation: Principles, Methodology, Advances, Applications, and Practice*. New York: John Wiley & Sons, 1998.

[2] A. M. Law, *Simulation Modeling and Analysis*. New York: McGraw-Hill, fifth ed., 2015.

[3] A. A. Cruz Roa, "3. input data analysis." Diapositivas del curso Simulación Computacional, Universidad de los Llanos, 2024.

[4] G. M. Ljung and G. E. P. Box, "On a measure of lack of fit in time series models," *Biometrika*, vol. 65, no. 2, pp. 297–303, 1978.

[5] P. Virtanen, R. Gommers, T. E. Oliphant, *et al.*, "SciPy 1.0: Fundamental algorithms for scientific computing in Python," *Nature Methods*, vol. 17, pp. 261–272, 2020.

[6] J. Amat Rodrigo, "Ajuste y selección de distribuciones con Python." Disponible con licencia CC BY-NC-SA 4.0 en https://www.cienciadedatos.net/documentos/pystats01-ajuste-distribuciones-python.html, 2021.

[7] H. Akaike, "A new look at the statistical model identification," *IEEE Transactions on Automatic Control*, vol. 19, no. 6, pp. 716–723, 1974.

[8] G. Schwarz, "Estimating the dimension of a model," *The Annals of Statistics*, vol. 6, no. 2, pp. 461–464, 1978.